Технологии и разработка СУБД

Полнотекстовый поиск в PostgreSQL

Анастасия Лубенникова
Александр Алексеев

Зачем использовать FTS в РСУБД?

- Примерно так же хорош, как в специализированном ПО
- Нет дублирования данных
- Консистентность данных
- Не нужно устанавливать и поддерживать дополнительное ПО

Основы полнотекстового поиска

to_tsvector

```
# SELECT to_tsvector('No need to install and maintain anything except PostgreSQL');
 'anyth':7 'except':8 'instal':4 'maintain':6 'need':2 'postgresql':9
(1 row)

# SELECT to_tsvector('russian',
                    'Не нужно устанавливать и поддерживать ничего кроме PostgreSQL');
 'postgresql':8 'кром':7 'нужн':2 'поддержива':5 'устанавлива':3
(1 row)
```

to_tsquery

```
# SELECT to_tsquery('install | maintain');
 'instal' | 'maintain'
(1 row)

# SELECT to_tsquery('russian', 'устанавливать & поддерживать');
 'устанавлива' & 'поддержива'
(1 row)
```

plainto_tsquery & phraseto_tsquery

```
# SELECT plainto_tsquery('install maintain');

 'instal' & 'maintain'

(1 row)


# SELECT phraseto_tsquery('russian', 'устанавливать поддерживать');

 'устанавлива' <-> 'поддержива'

(1 row)
```

tsvector @@ tsquery

```
# SELECT to_tsvector('No need to install and maintain anything except PostgreSQL') @@ plainto_tsquery('install maintain') AS match;

 match
-------
 t
```

Проблемка

- Это все здорово, но нам, наверное, нужны какие-то индексы

Индексы: GIN

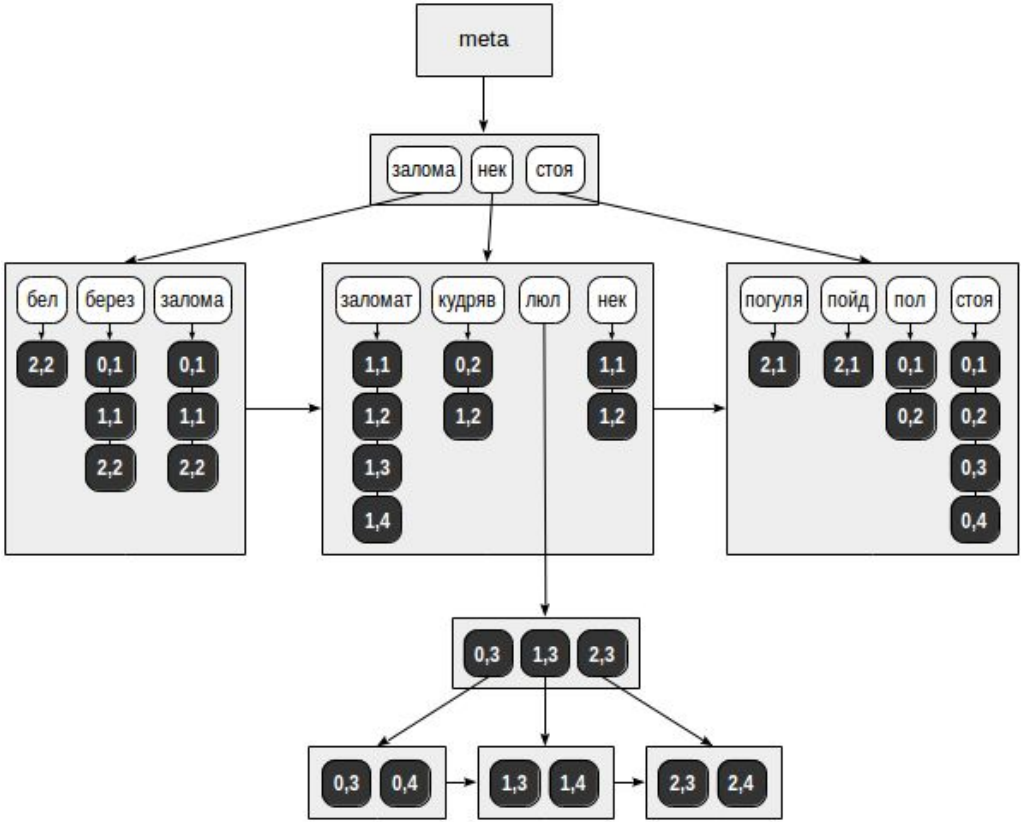
meta
залома
нек
стоя
бел
берез
залома
2,2
0,1
1,1
2,2
0,1
1,1
2,2
заломат
кудряв
люл
нек
1,1
1,2
1,3
1,4
0,2
1,2
1,1
1,2
погуля
пойд
пол
стоя
2,1
2,1
0,1
0,2
0,1
0,2
0,3
0,4
0,3
1,3
2,3
0,3
0,4
1,3
1,4
2,3
2,4

Индексы: GiST

Ищем сигнатуру 0010000

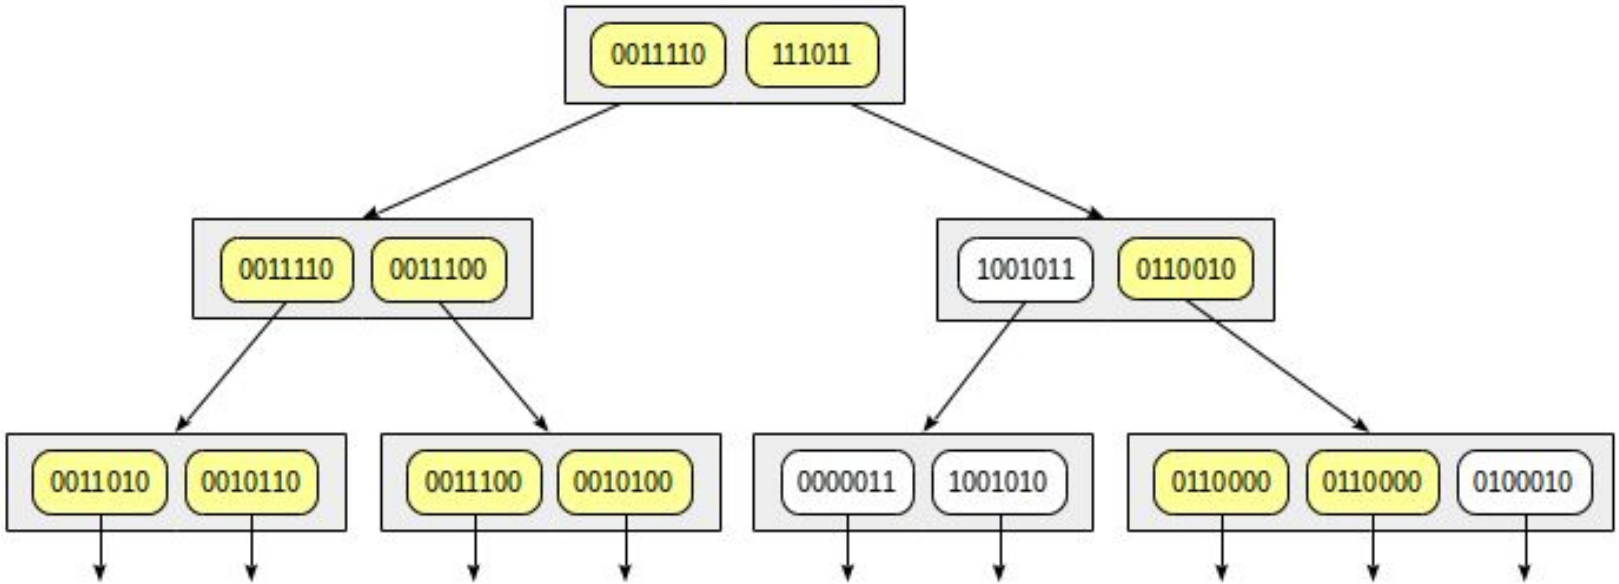

Индексы: GIN или GiST?

- GIN
  - быстрый поиск, не очень быстрые обновления
  - лучше для статических или редко изменяемых данных
- GiST
  - медленный поиск, более быстрые обновления
  - лучше для часто изменяющихся данных

Если сомневаетесь, используйте GIN.

Практика: 1 / 3

```
CREATE TABLE IF NOT EXISTS
  articles(id serial primary key, title varchar(128), content text);


-- https://meta.wikimedia.org/wiki/Data_dump_torrents#enwiki
-- https://github.com/afiskon/postgresql-fts-example
COPY articles FROM PROGRAM 'zcat /path/to/articles.copy.gz';
```

Практика: 2 / 3

```
CREATE OR REPLACE FUNCTION make_tsvector(title text, content text)
   RETURNS tsvector AS $$
BEGIN
  RETURN (setweight(to_tsvector('english', title),'A') ||
    setweight(to_tsvector('english', content), 'B'));
END
$$ LANGUAGE 'plpgsql' IMMUTABLE;
```

Практика: 3 / 3

```
CREATE INDEX IF NOT EXISTS idx_fts_articles ON articles
  USING gin(make_tsvector(title, content));
SELECT id, title FROM articles WHERE
  make_tsvector(title, content) @@ to_tsquery('bjarne <-> stroustrup');

  2470 | Binary search algorithm
  2129 | Bell Labs
  2130 | Bjarne Stroustrup
  3665 | C (programming language)
```

ts_headline: 1 / 2

```
SELECT id, ts_headline(title, q) FROM articles,
    to_tsquery('bjarne <-> stroustrup') AS q -- !!!
  WHERE make_tsvector(title, content) @@ q;
```

```
2470 | Binary search algorithm
2129 | Bell Labs
2130 | <b>Bjarne</b> <b>Stroustrup</b>
```

ts_headline: 2 / 2

```
SELECT id, ts_headline(title, q, 'StartSel=<em>, StopSel=</em>') -- !!!
  FROM articles, to_tsquery('bjarne <-> stroustrup') as q
  WHERE make_tsvector(title, content) @@ q;


  2470 | Binary search algorithm
  2129 | Bell Labs
  2130 | <em>Bjarne</em> <em>Stroustrup</em>
```

ts_rank

```
SELECT id, ts_headline(title, q, 'StartSel=<em>, StopSel=</em>')
  FROM articles, to_tsquery('bjarne <-> stroustrup') as q
  WHERE make_tsvector(title, content) @@ q
  ORDER BY ts_rank(make_tsvector(title, content), q) DESC;


  2130 | <em>Bjarne</em> <em>Stroustrup</em>
  3665 | C (programming language)
  6266 | Edsger W. Dijkstra
```

Проблемка

- Ранжирование данных производится в памяти

RUM

```
$ git clone git@github.com:postgrespro/rum.git

$ cd rum

$ USE_PGXS=1 make install

$ USE_PGXS=1 make installcheck


psql> CREATE EXTENSION rum;
```

Нечеткий поиск

pg_trgm: 1 / 4

```
create extension pg_trgm;

create index articles_trgm_idx on articles using gin (title gin_trgm_ops);
```

pg_trgm: 2 / 4

select show_trgm(title) from articles limit 3;

show_trgm | {" a"," ac",acc,ble,cce,ces,com,eco,ess,ibl,ing,lec,mpu,...

show_trgm | {" a"," an",ana,arc,chi,his,ism,nar,rch,"sm "}

show_trgm | {" a"," af",afg,anh,ani,fgh,gha,han,his,ist,nhi,nis,ory,...

pg_trgm: 3 / 4

select title, similarity(title, 'Straustrup') from articles where title % 'Straustrup';

-[RECORD 1]----------------

title | Bjarne Stroustrup

similarity | 0.35

pg_trgm: 4 / 4

```
psql> select show_limit();


-[ RECORD 1 ]---

show_limit | 0.3


psql> select set_limit(0.4);


-[ RECORD 1 ]--

set_limit | 0.4
```

pg_trgm: like / ilike queries

```
# explain select title from articles where title LIKE '%Stroustrup%';
                                QUERY PLAN
-------------------------------------------------------------------------------
 Bitmap Heap Scan on articles  (cost=60.02..71.40 rows=3 width=16)
   Recheck Cond: ((title)::text ~~ '%Stroustrup%'::text)
   ->  Bitmap Index Scan on articles_trgm_idx  (cost=0.00..60.02 rows=3...
         Index Cond: ((title)::text ~~ '%Stroustrup%'::text)
```

pg_trgm: regular expressions

```
# explain select title from articles where title ~* 'Stroustrup';
                                QUERY PLAN
-------------------------------------------------------------------------------
 Bitmap Heap Scan on articles  (cost=60.02..71.40 rows=3 width=16)
   Recheck Cond: ((title)::text ~* 'Stroustrup'::text)
   ->  Bitmap Index Scan on articles_trgm_idx  (cost=0.00..60.02 rows=3...
         Index Cond: ((title)::text ~* 'Stroustrup'::text)
```

Бонус: GIN & arrays

```
create table vec_test(id serial primary key, tags int[]);

create index vec_test_gin on vec_test using gin(tags);

insert into vec_test (tags) values ('{111,222,333}');


select * from vec_test where '{111}' <@ tags;

select * from vec_test where '{111}' @> tags;

select * from vec_test where '{111}' = tags;

-- intersection is not empty

select * from vec_test where '{111}' && tags;
```

Дополнительные материалы

- The **pg_trgm** module provides functions and operators for determining the similarity of alphanumeric text based on trigram matching
  - https://www.postgresql.org/docs/current/static/pgtrgm.html
- Full Text Search support for JSON and JSONB
  - https://www.depesz.com/2017/04/04/waiting-for-postgresql-10-full-text-search-support-for-json-and-jsonb/
- RUM access method
  - https://github.com/postgrespro/rum
- Подробнее о GIN - https://habrahabr.ru/company/postgrespro/blog/340978/
- Подробнее о GiST - https://habrahabr.ru/company/postgrespro/blog/333878/

Вопросы и ответы.

- a.lubennikova@postgrespro.ru
- a.alekseev@postgrespro.ru
- Telegram: https://t.me/dbmsdev